

Quand passer à la fenêtre de contexte étendue et à quel coût

Le contexte dépend du modèle

Modèle sur l'API directe	Contexte	Sortie maximale
Haiku 4.5	200K	64K
Sonnet 5	1M natif	128K
Opus 5.5	1M natif	128K
Fable 5.1	1M natif	128K

Vérifié le 24 septembre 2026. Le fournisseur peut imposer d'autres limites. Consulter `/context` pour la session active.

Pas de surcoût du 1M natif

Les modèles actuels à 1M natif gardent leurs tarifs standard au-delà de 200K tokens en entrée. L'ancien en-tête bêta n'est pas requis. Sonnet 5 n'a pas de variante 200K sur l'API directe. Opus 4.6 et Sonnet 4.6 proposent des variantes `[1m]` avec des restrictions de forfait et de fournisseur. Ces règles ne décrivent pas les modèles actuels.

Chiffrer une requête complète

Exemples en dollars, sans cache ni nouvelle tentative :

Entrée / sortie	Sonnet 5	Opus 5.5
50K / 5K	\$0.15	\$0.30
150K / 20K	\$0.50	\$1.00
500K / 50K	\$1.50	\$3.00

Séparer entrée, sortie, lecture et écriture du cache. La taille du contexte est une capacité, pas un coût ni un score de précision.

Maîtriser l'accumulation

`/context` détaille les tokens. `/compact` résume la conversation ; `/clear` repart de zéro. Enregistrer les décisions et les commandes de vérification avant de vider le contexte. `/autocompact 500k` enregistre une fenêtre plus petite. `/autocompact auto` rétablit le défaut du modèle. Une session à 1M natif compacte normalement vers 967K.

Charger les fichiers utiles plutôt que remplir la fenêtre. Séparer les tâches indépendantes quand cela facilite le travail. Aucun pourcentage fixe ne garantit le rappel des informations.

Évaluer la recherche d'information

Les anciens scores MRCR d'Opus 4.6 ou Sonnet 4.5 restent propres à ces modèles et au protocole du benchmark. Ils ne mesurent pas Sonnet 5 ou Opus 5.5. Tester son corpus avec questions vérifiables, citations attendues et distracteurs. Mesurer aussi les éléments de preuve manqués. Sources : [Configuration](#), [spécifications](#), [tarifs](#).