

Quand passer à la fenêtre de contexte étendue et à quel coût

Les Deux Fenêtres

Paramètre	200K standard	1M GA (Max/Team/Enterprise)
Disponibilité	Tous les plans	GA pour les plans Claude Code Max, Team, Enterprise (v2.1.75, mars 2026)
Header requis	Aucun	Aucun (plans CC) · Header API pour accès direct
Prix (input Opus)	\$5/MTok	\$10/MTok (API directe) · Inclus dans les plans CC sans surcoût
Max output	128K tokens	128K tokens

Au-dessus de 200K tokens en entrée, **tous les tokens du contexte** sont facturés au tarif premium, pas seulement l'excédent. C'est un palier de coût, pas une progression linéaire.

Précision à l'Échelle (MRCR v2)

Modèle	À 256K	À 1M
Opus 4.6	93%	76%
Sonnet 4.5	n/a	18.5%

Opus 4.6 reste utilisable à 1M (76% de précision), mais la dégradation est mesurable. Sonnet s'effondre et n'est pas recommandé au-delà de 200K pour des tâches précises.

Coût par Session (Approximatif)

Type de session	Tokens in	Sonnet 4.6	Opus 4.6
PR review (≤200K)	50K	~\$0.23	~\$0.38
Refactorisation (≤200K)	150K	~\$0.75	~\$1.25
Analyse service (>200K)	500K	~\$4.13	~\$6.88

Quand Utiliser 1M

La règle de la communauté : 200K + RAG par défaut, 1M Opus réservé aux cas où charger tout d'un coup est réellement nécessaire. Pour l'API directe, le header reste requis (tier 4+) ; les plans CC Max/Team/Enterprise l'ont inclus sans action supplémentaire.

Justifié : - Audit complet d'un codebase entier en une seule passe - Analyse de documentation massive sans possibilité de chunking - Agent Teams sur une architecture multi-services complexe

Non justifié : - Développement quotidien (même sur de gros projets) - Tâches avec feedback loop rapide (tests, debug) - Cas où /compact + sessions séquentielles fonctionnent

Activation (API)

Plans Claude Code Max, Team et Enterprise : le contexte 1M est activé automatiquement depuis v2.1.75 — aucun header nécessaire. La section ci-dessous concerne

uniquement l'accès API direct (appels Anthropic hors CLI Claude Code).

```
response = client.messages.create(model = "claude-opus-4-6", extra_headers = {"anthropic-beta": "context-1m-2025-08-07"}, messages = [...])
```

Sans ce header (accès API direct, comptes tier 4+), les requêtes dépassant 200K tokens retournent une erreur.

Pattern Recommandé

Travailler à 200K avec `/compact` proactif (à 70% de contexte) plutôt que d'activer 1M par défaut. Ouvrir une nouvelle session vers 70-75% d'utilisation : la performance est meilleure et le coût reste prévisible.

Pour la RAG sur gros documents, Gemini 1.5 Pro offre 2M de contexte à \$3.50/\$10.50 par MTok, soit 2-3x moins cher pour du retrieval pur sans besoin du raisonnement Opus.