

Le mode rapide et les changements API majeurs à connaître

Fast Mode

Fast Mode produit des réponses **2.5x plus rapides** en échange d'un coût 6x supérieur. Le modèle sous-jacent reste Opus 4.6, pas un modèle différent : c'est une allocation de ressources prioritaire, pas une simplification du raisonnement.

Paramètre	Standard	Fast Mode
Modèle	Opus 4.6	Opus 4.6
Vitesse	Référence	2.5x plus rapide
Prix input	\$5/MTok	\$30/MTok
Prix output	\$25/MTok	\$150/MTok

En CLI : `/fast` active le mode pour la session courante.

Quand Utiliser Fast Mode

Fast Mode est rentable quand le temps de réponse a une valeur métier directe : démo en direct, paire de programmation intensive, génération de code mécanique en boucle rapide. Ce n'est pas un remplacement de Sonnet pour les tâches simples, Sonnet reste 10x moins cher.

Pertinent : - Génération de boilerplate répétitif en session interactive - Reformatage ou conversion de code à grande échelle - Contexte de démo où la latence visible impacte l'expérience

Non pertinent : - Tâches de fond ou asynchrones (la vitesse ne compte pas) - Tâches simples couvrable par Sonnet ou Haiku - Budgets API serrés

Fast Mode via API (Opus 4.6)

```
response = client.messages.create(model = "claude-opus-4-6", speed = "fast", extra_headers = { "anthropic-beta" : "fast-mode-2026-02-01" }, messages = [{"role" : "user", "content" : "..."}])
```

Le header beta est obligatoire. Sans lui, le paramètre `speed` est ignoré silencieusement.

Breaking Change : `assistant-prefill` Supprimé

Opus 4.6 a retiré le support de l'**assistant prefill** : la technique qui permettait de pré-remplir la réponse de Claude pour guider son format de sortie.

```
# Avant (ne fonctionne plus sur Opus 4.6) messages = [ { "role" : "user", "content" : "Réponds en JSON" }, { "role" : "assistant", "content" : "{" } # prefill ] # Après - utiliser le system prompt system = "Always respond with valid JSON only."
```

Impact : tout pipeline API utilisant `assistant-prefill` sur Opus 4.6 doit migrer vers des instructions explicites dans le system prompt ou des exemples few-shot.

Paramètre `effort` (API)

Le paramètre `effort` remplace `budget_tokens` sur Opus 4.6 pour contrôler la profondeur de raisonnement.

```
output_config = { "effort" : "medium" } # low|medium|high|max
```

`budget_tokens` reste fonctionnel sur Opus 4.5 mais est déprécié sur 4.6. Migrer vers `effort` pour les nouveaux pipelines.

Résumé des Changements Opus 4.6

Fonctionnalité	Statut
<code>assistant-prefill</code>	Supprimé
<code>budget_tokens</code>	Déprécié (remplacé par <code>effort</code>)
Fast Mode	Nouveau (<code>speed: "fast"</code>)
Adaptive Thinking	Nouveau (remplace thinking opt-in)