

Le mode rapide et les changements API majeurs à connaître

Fast Mode sur Opus 5.5

Fast mode accélère le service du même modèle. Anthropic annonce une sortie **jusqu'à 2,5 fois plus rapide**, sans garantie pour chaque requête. Claude Code sélectionne Opus 5.5 en fast mode depuis la v2.1.280.

Prix par million de tokens	Standard	Fast
Entrée	\$4	\$8
Sortie	\$20	\$40

Opus 5 et Opus 4.8 acceptent aussi fast mode à \$10/\$50. Sonnet et Haiku ne le proposent pas. Opus 4.7 n'est plus pris en charge en fast mode.

Activation et facturation

Utiliser `/fast` ou `Option+0` / `Alt+0`. Le choix persiste normalement entre les sessions, sous réserve des règles de l'organisation et de la disponibilité. Avec un abonnement, fast mode consomme des crédits d'usage.

Comparer latence et coût sur une même tâche. Une sortie plus rapide ne supprime pas les attentes d'outils, les reprises ni la relecture. Sonnet 5 standard coûte \$2/\$10, soit quatre fois moins qu'Opus 5.5 fast à nombre de tokens égal.

Intégration API

Consulter les [instructions API fast mode](#) pour les modèles, en-têtes, paramètres et règles de repli actuels. Vérifier la compatibilité du SDK avant de reprendre un ancien exemple bêta.

Pour le raisonnement adaptatif :

```
response = client.messages.create(  
    model="claude-opus-5-5",  
    max_tokens=16000,  
    thinking={"type": "adaptive"},  
    output_config={"effort": "high"},  
    messages=[{"role": "user", "content": "Review  
this design."}],  
)
```

Cet exemple utilise la vitesse standard. Opus 5.5 démarre à medium dans Claude Code ; ici, high est demandé explicitement.

Migrer les anciens exemples

Opus 4.6 a supprimé le préremplissage assistant. Pour du JSON contraint par un schéma, utiliser `output_config.format`.

Pour les arguments d'outils, placer `strict: true` sur la définition de l'outil. Une consigne système seule ne garantit pas un JSON valide.

Les Opus actuels, Sonnet 5 et Fable utilisent le thinking adaptatif. Les exemples avec `budget_tokens` fixe concernent d'anciens modèles. Haiku 4.5 accepte le thinking étendu, mais pas le paramètre effort.

Vérifié le 24 septembre 2026. Sources : [Fast mode Claude Code](#), [sorties structurées](#).